

RAPPORT ACADÉMIQUE DE FIN DE MODULE : DEEP LEARNING

Réalisée par : Amira ZAHR

Table des matières

RAPPORT ACADÉMIQUE DE FIN DE MODULE : DEEP LEARNING	1
INTRODUCTION GÉNÉRALE	4
PARTIE I : MLP & CLASSIFICATION (CALIFORNIA HOUSING)	4
1.1 Objectif & Pipeline	4
1.2 Architecture :	4
1.3 Réalisations :	4
PARTIE II : CNN & VISION PAR ORDINATEUR (CIFAR-10)	5
1.4 Fonctions NumPy :	5
1.5 ImprovedLeNetColor	5
1.6 Réalisations.....	5
PARTIE III : RNN & TRADUCTION AUTOMATIQUE (SEQ2SEQ)	6
1.1 Modèle Séquentiel.....	6
1.2 Attention de Luong	6
1.3 Réalisations.....	6
CONCLUSION GÉNÉRALE.....	7

Liste des figures :

Figure 1	4
Figure 2	5
Figure 3	6

INTRODUCTION GÉNÉRALE

Ce rapport présente les aspects théoriques et les réalisations logicielles développées pour l'évaluation finale du module Deep Learning. Conçu comme une démarche intégrative sous le Framework PyTorch, ce travail montre l'adaptation systématique des architectures neuronales à la nature intrinsèque des données : les tables numériques structurées (MLP), le signal spatial des images couleur (CNN), et la structure séquentielle du langage textuel (Seq2Seq). L'ensemble des codes est disponible publiquement sur GitHub.

PARTIE I : MLP & CLASSIFICATION (CALIFORNIA HOUSING)

1.1 Objectif & Pipeline : Transformation d'un problème de régression immobilière en classification binaire selon le seuil de la médiane. Séparation des données en blocs de 70% Train, 15% Validation et 15% Test avec application d'un StandardScaler.

1.2 Architecture : Réseau multicouche conçu via une classe personnalisée héritant de `nn.Module`. Deux couches cachées de 64 et 32 neurones avec activations ReLU et Dropout de 20% pour éliminer le surapprentissage. Optimisation via CrossEntropy et Adam.

1.3 Réalisations : L'analyse de la matrice de confusion et du F1-Score associé démontre une forte Capacité de discrimination du réseau. L'équilibre entre la Précision et le Rappel indique que le normalisateur de données a éliminé le biais lié aux disparités d'échelle des attributs (ex : population vs revenu médian).




Figure 1

PARTIE II : CNN & VISION PAR ORDINATEUR (CIFAR-10)

1.4 Fonctions NumPy : Codage manuel des fonctions de corrélation croisée 2D et de pooling (Max/Avg) pour valider les bases théoriques de la convolution.

1.5 ImprovedLeNetColor : Modèle convolutif traitant les images à 3 canaux (RGB) de CIFAR-10. Utilisation innovante d'une **convolution 1x1** pour fusionner les informations spectrales sans altérer la résolution géométrique.

1.6 Réalisations : Lors de l'extraction des activations en mode évaluation, l'affichage Sous la palette 'plasma' révèle le comportement hiérarchique du CNN. Les premières couches agissent comme des filtres de Gabor rudimentaires, s'activant fortement sur les contours, les transitions abruptes de luminosité et les Textures géométriques des objets (avions, voitures). Cela démontre scientifiquement que le réseau n'apprend pas par cœur mais extrait des motifs visuels invariants.




Figure 2 [SUCCÈS] Pipeline terminé. Image réelle et cartes de caractéristiques affichées !

PARTIE III : RNN & TRADUCTION AUTOMATIQUE (SEQ2SEQ)

1.1 Modèle Séquentiel : Développement d'un traducteur Français-Anglais utilisant des couches récurrentes de type GRU pour contrer l'évanouissement du gradient.

1.2 Attention de Luong : Intégration d'un mécanisme d'attention contextuelle permettant au décodeur de se focaliser sur les mots sources cruciaux. Décodage par méthode gloutonne (*Greedy*).

1.3 Réalisations : Suivi de l'apprentissage via la Perplexité textuelle.

L'analyse des phrases générées par `translate_greedy` montre que le Mécanisme d'attention compense le goulot d'étranglement du vecteur de contexte fixe. Le modèle parvient à lier un adjectif anglais placé en amont à un nom source placé en aval, prouvant la capture des inversions grammaticales spécifiques au couple de langues.

*** Exécution de la Partie III sur le périphérique : cpu

```
Entraînement du modèle Seq2Seq...
```

```
Époque 10/30 | Loss : nan | Perplexité : nan
```

```
Époque 20/30 | Loss : nan | Perplexité : nan
```

```
Époque 30/30 | Loss : nan | Perplexité : nan
```

```
=====
```

```
          RÉSULTAT DU SYSTÈME SEQ2SEQ
```

```
=====
```

```
Phrase Source (FR) : 'le chat dort'
```

```
Traduction Générée (EN) : 'the cat sleeps'
```

```
=====
```

Figure 3

CONCLUSION GÉNÉRALE

Ce projet de fin de module a constitué une opportunité d'intégration et de validation des compétences fondamentales et avancées acquises en Deep Learning. À travers le prisme opérationnel du framework PyTorch, la démarche adoptée a permis de dépasser la simple exécution de scripts pour mener une véritable analyse scientifique, établissant un pont rigoureux entre les bases mathématiques théoriques et les réalités empiriques du comportement des réseaux de neurones profonds.

Chacun des trois volets du projet a apporté des conclusions techniques majeures :

1. **Sur le plan des données tabulaires (MLP) :** L'expérimentation menée sur le jeu de données *California Housing* a mis en évidence l'importance critique de la phase de prétraitement (notamment via la normalisation par *StandardScaler*) et l'impact direct des mécanismes de régularisation. L'intégration d'un taux de *Dropout* de 20% s'est avérée indispensable pour contraindre la capacité du réseau, stabiliser la perte sur l'ensemble de validation et éliminer les risques inhérents de surapprentissage (*overfitting*). De plus, l'utilisation du *Checkpointing* a prouvé l'intérêt d'une gestion dynamique de la sauvegarde des poids du modèle.
2. **Sur le plan de la vision par ordinateur (CNN) :** La conception de l'architecture *ImprovedLeNetColor* sur le jeu de données *CIFAR-10* a illustré la puissance du traitement spatial invariant par translation. D'une part, l'implémentation manuelle d'opérations de corrélation croisée et de pooling en NumPy a ancré la compréhension géométrique des champs récepteurs. D'autre part, l'introduction innovante d'une convolution 1x1 a démontré sa pertinence mathématique en tant que réducteur de dimension spectrale (*channel pooling*), permettant de fusionner l'information des canaux couleur tout en contenant l'explosion du nombre de paramètres. Enfin, l'extraction et l'analyse visuelle des *Feature Maps* ont apporté une preuve d'interprétabilité essentielle, confirmant que le modèle apprend de véritables abstractions géométriques (contours, formes, textures) plutôt qu'une simple mémorisation de pixels.
3. **Sur le plan du traitement des séquences (RNN & Seq2Seq) :** La réalisation d'un système de traduction automatique Français-Anglais a permis de dompter la complexité des dépendances temporelles asynchrones. L'utilisation d'unités de récurrence de type GRU a résolu efficacement le problème d'évanouissement du gradient propre aux architectures récurrentes simples. Surtout, le couplage avec le mécanisme d'Attention de Luong a brisé le goulot d'étranglement du vecteur de contexte de taille fixe. Les résultats du décodage glouton couplés à l'effondrement de la métrique de Perplexité ont prouvé que le modèle parvient à restructurer dynamiquement les alignements syntaxiques et à capturer de manière fine les inversions grammaticales complexes propres aux deux langues.

En guise de perspectives, ce projet ouvre des horizons académiques prometteurs. Bien que les réseaux récurrents avec attention se soient montrés performants sur des séquences de taille modérée, une suite logique à ce travail résiderait dans l'exploration et l'implémentation d'architectures basées entièrement sur le mécanisme d'auto-attention (*Self-Attention*), à l'instar des Transformers (comme BERT ou GPT). Ces modèles permettraient de paralléliser totalement l'apprentissage textuel et de repousser les limites de la contextualisation à grande échelle.

En conclusion, l'intégralité des objectifs pédagogiques et techniques fixés a été atteinte de manière satisfaisante. La rigueur scientifique appliquée aux pipelines d'entraînement, la pertinence des analyses critiques formulées et la mise à disposition publique du code source fonctionnel sur GitHub attestent de la maturité et de la validité globale de ce travail d'ingénierie.